

5G NR 下行波束赋形码本演进总结 (R15-R20)

这份笔记按 R15 到 R20 的演进主线整理 5G NR 下行 beamforming codebook。重点关注：

UE 如何用有限 PMI 反馈，让 gNB 重构一个足够好的下行 precoder。

从整体上看，5G NR 下行码本的演进可以概括为：

single beam → multi-beam → beam + tap → port + tap → beam + tap + shift → large-port / AI feedback.

对应到 release：

Release / Codebook	核心对象	压缩维度	关键思想
R15 Type I	单个或一组 DFT beams	空间	低开销 beam selection
R15 Type II	多个 DFT beams + 幅相系数	空间	高精度 multi-beam combination
R16 Enhanced Type II	beams + delay taps	空间 + 频率	对宽带 precoder 做联合空间-频域压缩
R17 Further Enhanced Port-Selection Type II	ports + delay taps	port/空间 + 频率	任意 port selection, 降低 tap 反馈复杂度
R18 Predicted PMI Type II	beams + taps + shifts	空间 + 频率 + 时间	用 predicted PMI 表达未来时刻的 precoder 变化
R19 Refined Codebooks	large-port beams / ports	大端口空间维度	支持 48/64/128 CSI-RS ports 与 refined feedback
R20 Study Items	lower-overhead CSI acquisition / AI feedback	测量开销 + 学习型反馈	降低 large-port CSI-RS 开销，并研究 AI/ML CSI feedback

1. 波束赋形的基础背景

1.1 Beamforming 在下行 MIMO 中解决什么

在下行 OFDM MIMO 系统中，beamforming 的目标不是简单地“把能量打向某个方向”，而是在 **阵列增益、空间复用、干扰抑制** 之间做折中。对于第 k 个 UE、第 m 个子载波，接收信号可写为：

$$\mathbf{y}_k[m] = \mathbf{H}_k[m]\mathbf{W}_k[m]\mathbf{s}_k[m] + \sum_{i \neq k} \mathbf{H}_k[m]\mathbf{W}_i[m]\mathbf{s}_i[m] + \mathbf{n}_k[m].$$

其中：

- $\mathbf{H}_k[m]$ ：第 k 个 UE 在第 m 个子载波上的下行信道；
- $\mathbf{W}_k[m]$ ：gNB 给该 UE 使用的 precoding / beamforming 矩阵；
- $\mathbf{s}_k[m]$ ：发送给该 UE 的数据流；
- $\sum_{i \neq k} \mathbf{H}_k[m]\mathbf{W}_i[m]\mathbf{s}_i[m]$ ：其他 UE 或其他 layer 带来的干扰；
- $\mathbf{n}_k[m]$ ：噪声。

因此，设计 $\mathbf{W}_k[m]$ 的难点在于：它既要增强目标 UE 的接收信号，又要支持多流传输，还要尽量减少层间和用户间干扰。

1.2 Full CSI 与 codebook-based beamforming

如果 gNB 掌握完整下行 CSI，就可以直接优化 precoder，例如用 WMMSE 等方法求解。TDD 中可以通过上下行互易性和 SRS 获取下行 CSI 的近似，但它依赖硬件校准、上行导频质量和信道时变速度。

在 FDD 中，上下行频段不同，gNB 不能直接从上行信道推断下行信道。如果 UE 把完整下行 CSI 原样反馈给 gNB，开销会非常大。因此 3GPP 采用 **codebook-based beamforming**：

1. gNB 和 UE 共享一套结构化码本；
2. UE 测量 CSI-RS 后，在码本中选择合适的 precoder；
3. UE 不反馈完整信道，而是反馈该 precoder 的索引，即 **PMI (Precoding Matrix Indicator)**；
4. gNB 根据 PMI 重构或近似重构下行 precoder。

所以 PMI 的本质不是信道本身，而是一个压缩后的 precoder 描述。5G NR 下行码本的演进，本质上就是在回答：

如何用越来越少、越来越结构化的 PMI 字段，表达越来越复杂的下行 precoder。

以下用一个理想化的单用户 MIMO 例子说明“码本”到底在传输链路中做什么。假设某个频域位置上的下行信道矩阵为 H 。UE 接收到 CSI-RS 后，可以估计该下行信道，并对信道做奇异值分解：

$$H = U\Sigma V^H.$$

其中， V 是右奇异矩阵，它的列向量代表信道的最优发射空间方向，也就是理想情况下的预编码方向。如果 gNB 想最大化接收端 SNR 或容量，并且没有反馈开销限制，那么它应当使用 V 中对应较大奇异值的列作为预编码矩阵 W 。例如 rank 为 r 时，可以取：

$$W_{\text{ideal}} = V_r.$$

这里 V_r 表示 V 中对应前 r 个主奇异值的列向量组成的矩阵。

但真实系统中，UE 不能把连续浮点矩阵 V 原样回传给 gNB。码本机制的核心就是把连续空间中的最优预编码方向量化成有限集合。预定义码本可以记为：

$$C = \{W_0, W_1, \dots, W_{N_{\text{cb}}-1}\}.$$

UE 在码本中寻找一个与真实最优方向最接近、或者能带来最好链路性能的码字。这个选择可以抽象为：

$$W_{\text{opt}} = \arg \max_{W \in C} f(H, W).$$

这里的 $f(H, W)$ 可以是接收 SNR、吞吐量、SINR、容量近似，也可以是与右奇异子空间距离相关的度量。随后 UE 不需要回传 W_{opt} 的矩阵元素，只需要回传它在码本中的索引：

$$\text{PMI} = \text{index}(W_{\text{opt}}).$$

因此，传递 PMI 本质上就是在传递 **高度量化和压缩后的信道主右奇异向量 / 右奇异子空间**。后续 R15 到 R20 的各种 codebook 设计，都是在同一个问题上做不同折中：如何用有限 bit 数更准确地描述 V 所代表的最优发射空间，并兼顾宽带频率选择性、端口数增长、时间预测和反馈开销。

需要注意，这个 SVD 图像是理解码本最清楚的入口，但 3GPP 真实 PMI 选择未必显式要求 UE 做 SVD。UE 实现可以直接枚举码本并计算每个候选 precoder 的预期 CQI/SINR/吞吐量，然后选择最优 PMI。SVD 只是说明：码本量化的目标，本质上是下行信道的优良发射子空间。

1.3 为什么单流也可能需要多个波束

一个容易误解的问题是：如果只有一个数据流，为什么还要组合多个 beams？

原因是“单流”只表示发送的数据符号维度为 1，并不表示无线信道只有一个角度方向。真实下行信道通常由多条散射路径叠加：

$$\mathbf{h} \approx \sum_{p=0}^{P-1} \alpha_p \mathbf{a}(\theta_p, \phi_p),$$

其中 α_p 是第 p 条路径的复增益， $\mathbf{a}(\theta_p, \phi_p)$ 是对应角度方向的阵列响应。即使 rank 为 1，最优 precoder 也可能更接近多个角域分量的组合，而不是某一个 DFT beam。

这就是 Type II multi-beam combination 的直觉：**单流不等于单路径，单 layer 也可能需要多个空间基底来逼近最优方向。**

2. CSI-RS 测量与 PMI 反馈闭环

2.1 标准中的基本闭环

3GPP 中 codebook-based beamforming 的基本闭环可以概括为四步：

1. **RRC 配置**：gNB 配置 CSI-RS resource 和 CSI report，包括码本类型、CSI-RS port 数、rank 限制、子带粒度、反馈周期等。
2. **发送 CSI-RS**：gNB 在配置的 CSI-RS ports 上发送参考信号，UE 测量下行有效信道。
3. **UE 形成 CSI report**：UE 根据测量结果选择 RI、PMI、CQI、CRI、LI 等反馈字段。
4. **gNB 重构 precoder**：gNB 根据 PMI 在码本中恢复或近似恢复 UE 建议的预编码矩阵，并用于 PDSCH 传输。

这里的关键是：UE 反馈的是 **建议的 precoder 结构**，不是完整信道矩阵。

2.2 CSI-RS port 是逻辑端口

CSI-RS port 是协议中的逻辑端口，不一定等于物理天线，也不一定等于 RF chain。UE 实际测到的往往不是原始物理阵列信道，而是经过 gNB 端口映射和可能的外部波束赋形后的 **effective channel**。

可以把这一点理解为：

$$\mathbf{H}_{\text{eff}} = \mathbf{H}_{\text{phy}} \mathbf{F}_{\text{PEB}},$$

其中 $\mathbf{H}_{\text{phy}}$ 是物理阵列信道， $\mathbf{F}_{\text{PEB}}$ 是 gNB 侧从物理天线到 CSI-RS ports 的映射或预波束形成矩阵。UE 基于 $\mathbf{H}_{\text{eff}}$ 选 PMI，而不是直接基于 $\mathbf{H}_{\text{phy}}$ 。

2.3 PMI、RI、CQI 的关系

PMI 通常不是孤立工作的，它和 RI、CQI 一起形成 CSI report：

- **RI (Rank Indicator)**：建议传输几个 layers；
- **PMI**：在该 rank 下建议使用哪个 precoder；
- **CQI**：在该 precoder 和 rank 下，UE 估计可支持的调制编码等级；
- **CRI/LI**：分别与 CSI-RS resource 和 layer 指示有关。

因此，PMI 的实际含义是：在给定测量资源、rank 假设和码本配置下，UE 对 gNB 的 precoder 建议。

3. 码本基础：PEB、DFT 波束基、regular 与 port-selection

3.1 PEB 决定 UE 看到什么

PEB (Port External Beamforming) 描述物理阵列到 CSI-RS ports 的映射方式。它决定 UE 看到的是更接近“逻辑天线域”的信道，还是更接近“beam-domain”的信道。

在 **sub-connected PEB** 中，每个 CSI-RS port 只映射到一个子阵列。UE 看到的更像 logical antenna-domain channel，因此更适合 regular codebook。

在 **full-connected PEB** 中，每个 CSI-RS port 都可以由整个物理阵列形成一个预波束。UE 看到的是 beam-domain effective channel，因此更适合 port-selection codebook。

这一区分非常重要：

- regular codebook: UE 在协议定义的 DFT beam basis 中选择或组合 beam;
- port-selection codebook: gNB 先把 CSI-RS ports 做成预波束，UE 再选择这些 beam-ports。

3.2 一维和二维 DFT 波束基

对一个 N 阵元 ULA，不考虑过采样时，标准 DFT beam 可写为：

$$\mathbf{a}_l = \frac{1}{\sqrt{N}} [1 \quad e^{j2\pi l/N} \quad \dots \quad e^{j2\pi(N-1)l/N}]^T, \quad l = 0, \dots, N-1.$$

对于双极化 UPA，若水平方向有 N_H 个阵元，垂直方向有 N_V 个阵元，则单极化二维空间基可以写成水平和垂直 steering vector 的 Kronecker 积：

$$\mathbf{v}_{l,m} = \hat{\mathbf{a}}_l \otimes \hat{\mathbf{u}}_m.$$

其中 $\hat{\mathbf{a}}_l$ 是水平方向 oversampled DFT beam， $\hat{\mathbf{u}}_m$ 是垂直方向 oversampled DFT beam。过采样形式可写为：

$$\hat{\mathbf{a}}_l = \frac{1}{\sqrt{N_H}} [1 \quad e^{j2\pi l/(N_H O_H)} \quad \dots \quad e^{j2\pi(N_H-1)l/(N_H O_H)}]^T,$$

$$\hat{\mathbf{u}}_m = \frac{1}{\sqrt{N_V}} [1 \quad e^{j2\pi m/(N_V O_V)} \quad \dots \quad e^{j2\pi(N_V-1)m/(N_V O_V)}]^T.$$

过采样因子 O_H, O_V 的作用是让角度网格更密，从而更接近真实 AoD。

3.3 Oversampled beams 为什么能分成多个正交组

所有 oversampled beams 放在一起并非两两正交，但可以按余数类划分成多个正交组。水平方向可以令：

$$l = r_H + qO_H, \quad r_H \in \{0, \dots, O_H - 1\}, \quad q \in \{0, \dots, N_H - 1\}.$$

也就是按 $l \bmod O_H$ 分组。同一组内两个 beam 的索引差是 $(q - q')O_H$ ，代入相位项后会退化为标准 N_H 点 DFT 列向量之间的内积，因此组内正交。

垂直方向同理：

$$m = r_V + pO_V, \quad r_V \in \{0, \dots, O_V - 1\}, \quad p \in \{0, \dots, N_V - 1\}.$$

二维正交组为：

$$G_{r_H, r_V} = \left\{ \mathbf{v}_{r_H+qO_H, r_V+pO_V} \mid q = 0, \dots, N_H - 1, p = 0, \dots, N_V - 1 \right\}.$$

因此，一共有 $O_H O_V$ 个二维正交组，每组有 $N_H N_V$ 个 beams。协议中很多 beam 选择过程都可以理解为：先确定一个 oversampled DFT group，再在该 group 内选择 beam 或 beam subset。

3.4 Regular 与 port-selection 的完整对比

regular codebook 和 port-selection codebook 都是在“选波束”，但抽象层次不同。

regular codebook 的空间基是协议定义的 DFT beam：

$$\mathbf{W}_s = \text{DFT beam basis.}$$

UE 反馈的是 DFT beam index 以及相关组合系数。Type II regular codebook 中，一个单流 precoder 可以抽象为：

$$\mathbf{w}_{\text{reg}} = \frac{1}{\sqrt{\beta}} \begin{bmatrix} \sum_{i=0}^{L-1} a_{1,i} \mathbf{v}_{l_i, m_i} \\ \sum_{i=0}^{L-1} a_{2,i} \mathbf{v}_{l_i, m_i} \end{bmatrix}.$$

这里 $\mathbf{v}_{l_i, m_i}$ 是被选中的 DFT beam basis, $a_{1,i}, a_{2,i}$ 是两个极化方向上的复系数。

port-selection codebook 的空间基则是 one-hot standard basis：

$$\mathbf{p}_d = [0 \quad \dots \quad 1 \quad \dots \quad 0]^T.$$

如果 gNB 通过 PEB 形成：

$$\mathbf{F} = [\mathbf{v}_0 \quad \mathbf{v}_1 \quad \dots \quad \mathbf{v}_{P_{\text{CSI-RS}}/2-1}],$$

那么 UE 看到的是：

$$\mathbf{H}_{\text{eff}} = [\mathbf{H}_1 \mathbf{F} \quad \mathbf{H}_2 \mathbf{F}].$$

在 port-selection 中，UE 表面上是在选择 $\mathbf{p}_d$ 这样的 port basis；但代入 PEB 后，本质上是在选择 gNB 预先形成的物理波束。

二者可以用下表概括：

维度	Regular codebook	Port-selection codebook
UE 看到的信道	逻辑天线/逻辑端口域信道	beam-domain effective channel
典型 PEB	无 PEB 或 sub-connected PEB	full-connected PEB
空间基	DFT beam basis $\mathbf{v}_{l,m}$	one-hot port basis $\mathbf{p}_d$
选择对象	DFT beams	CSI-RS ports / beam-ports
gNB/UE 分工	UE 直接反馈 DFT beam index 和组合系数	gNB 先设计 port-beams, UE 反馈哪些 ports 有用
适用场景	逻辑阵列、fully digital、sub-connected 结构	hybrid beamforming、mmWave、角域稀疏信道

一句话总结：

regular 是“在码本内部生成波束”，port-selection 是“在 gNB 已经生成的 beam-ports 中做选择”。

4. R15: Type I 与 Type II 的空间域码本

4.1 R15 的总体定位

R15 是 NR 下行码本的基础版本，主要解决 **如何在有限反馈下表示空间预编码**。它的核心分支是 Type I 和 Type II：

- **Type I**：低复杂度、低开销，偏 beam selection；
- **Type II**：高精度、较高开销，偏 multi-beam reconstruction。

4.2 Type I: 低复杂度 beam selection

Type I 的设计思想是低复杂度、低反馈。UE 从预定义 DFT beam 或 beam group 中选择较好的方向，再反馈少量相位、极化和 rank 相关信息。

Type I Mode 1 可以理解为：

- 宽带选择一个二维 DFT beam；
- 双极化共享该空间 beam；
- 通过少量相位字段描述两个极化之间的相对关系；
- 多流时通过预定义 offset 形成不同 layer 的 beam 差异。

Type I Mode 2 则引入 beam group refinement：宽带先选一个 beam group，子带再在组内选择更合适的 beam。这比 Mode 1 更灵活，但仍然是“单 beam / 小范围 refinement”的思路。

因此 Type I 的特点是：

- 反馈开销小；
- UE 计算复杂度低；
- 对单流或低 rank 场景友好；
- 在大阵列、高 rank、强频率选择性场景中精度有限。

4.3 Type II: 高精度 multi-beam combination

Type II 的关键变化是：precoder 不再只由一个 beam 表示，而是由多个 DFT beams 的线性组合表示。

R15 Type II 先选择 L 个空间 beams：

$$\hat{\mathbf{W}}_s = [\mathbf{v}_{l_0, m_0} \quad \mathbf{v}_{l_1, m_1} \quad \cdots \quad \mathbf{v}_{l_{L-1}, m_{L-1}}] \cdot$$

然后反馈每个 beam 在不同极化、layer、subband 上的幅度和相位系数。单个 precoder 可以理解为：

$$\mathbf{w} = \hat{\mathbf{W}}_s \mathbf{w}_{\text{PMI}} \cdot$$

这里 $\mathbf{w}_{\text{PMI}}$ 是由 PMI 指示的稀疏系数向量。

Type II 相比 Type I 的提升在于：

- Type I 更像“选一个最接近的 beam”；
- Type II 更像“用多个 beam 重构一个更准确的 precoder”。

这也是为什么 Type II 在大阵列、高 rank、多径角度分量丰富时更有优势。

4.4 R15 的宽带/子带层次

R15 Type II 已经有宽带和子带层次：宽带反馈空间 beam skeleton，子带反馈不同频率位置上的幅相修正。可以近似写为：

$$\mathbf{w}[m] = \hat{\mathbf{W}}_s \mathbf{c}[m],$$

其中 m 表示子带索引， $\mathbf{c}[m]$ 是该子带上的 beam 系数。

但 R15 还没有显式把 $\mathbf{c}[m]$ 随频率的变化建模成一个低维结构。换句话说，R15 的宽带/子带机制更像 hierarchical refinement，而不是完整的空间-频率联合压缩。

5. R16: Enhanced Type II 的联合空间-频域压缩

5.1 R16 相比 R15 的关键变化

R16 Enhanced Type II 的核心升级是：在 R15 Type II 的空间多 beam 表示基础上，引入频域 / delay-domain 基底，从而对整个宽带上的 precoder 序列进行联合压缩。

R15 可以理解为：

$$\mathbf{w}[m] = \hat{\mathbf{W}}_s \mathbf{c}[m], \quad m = 0, \dots, N_3 - 1.$$

R16 则认为，不同频域位置上的 $\mathbf{c}[m]$ 不是彼此独立的，而是具有频域相关性，可以用少量 delay taps 表示：

$$\mathbf{W} = \hat{\mathbf{W}}_s \mathbf{W}_c \hat{\mathbf{W}}_f^T.$$

其中：

- $\hat{\mathbf{W}}_s$ ：选中的空间 beam basis；
- $\hat{\mathbf{W}}_f$ ：选中的 frequency / delay-domain basis；
- $\mathbf{W}_c$ ：beam-tap 域上的稀疏系数矩阵；
- $\mathbf{W}$ ：多个频域采样点上的 precoder 集合。

这就是 R16 的关键思想：

不再对每个子带独立反馈空间组合系数，而是用少量空间 beams 和少量 delay taps 共同生成整个 BWP 上的 precoder。

5.2 R16 的 frequency basis 不是 OFDM 的 IFFT

另一个容易混淆的问题是：OFDM 本身已经用了 DFT/IFFT，为什么 R16 还要 frequency basis？

二者处理的对象不同：

- OFDM 的 DFT/IFFT：在时域波形和频域子载波之间变换；
- R16 的 frequency basis：压缩 **precoder 随频率变化的结构**。

也就是说，R16 不是在重复 OFDM 的功能，而是在说：不同 subbands 上的最优 precoder 并不是完全无关的，它们由同一组多径时延结构驱动，因此可以在 delay-domain 中稀疏表示。

5.3 如果子带之间只是相位旋转，是否真的需要微调

这里有一个很关键的直觉问题：如果不同子载波上的预编码矩阵只是多了一个相位旋转，那么接收信号不也只是乘了一个复数相位吗？这是否不影响 SNR？

答案是：**如果只是公共标量相位旋转，确实不影响 SNR；但 R15/R16 中的子带微调 and 频域压缩主要不是为了反馈这种无关紧要的公共相位，而是为了描述不同频率上 precoder 的空间方向、相对幅相和层间结构变化。**

以单用户、单流为例，第 m 个子载波上的接收信号可以写成：

$$y[m] = \mathbf{h}[m]^H \mathbf{w}[m] s[m] + n[m].$$

如果预编码向量只是公共相位旋转：

$$\mathbf{w}[m] = e^{j\phi[m]} \mathbf{w}_0,$$

那么有效信道变成：

$$\mathbf{h}[m]^H \mathbf{w}[m] = e^{j\phi[m]} \mathbf{h}[m]^H \mathbf{w}_0.$$

由于

$$|e^{j\phi[m]} \mathbf{h}[m]^H \mathbf{w}_0|^2 = |\mathbf{h}[m]^H \mathbf{w}_0|^2,$$

这个公共相位不会改变接收功率，也不会改变单流 SNR。实际系统中，DM-RS 还会帮助 UE 估计等效信道相位，所以这种公共相位通常可以被接收机吸收。

矩阵情形也类似：如果整个 precoding matrix 只是乘了一个公共相位，或者每个 layer 只是乘了各自的单位模相位，在理想单用户接收和 DM-RS 估计下通常不会改变接收功率本身。真正可能改变 SINR 的，是 precoder 的列空间、不同 beams 的相对系数、不同 layers 之间的正交性，以及多用户之间的干扰关系发生变化。

真正重要的是 **相对变化**。Type II precoder 通常是多个空间 beams 的组合：

$$\mathbf{w}[m] = \sum_{l=0}^{L-1} c_l[m] \mathbf{v}_l.$$

如果所有系数都只是乘同一个相位，即 $c_l[m] = e^{j\phi[m]} c_l[0]$ ，那么 beam pattern 没有本质变化。但如果不同 beam 的系数发生不同的相位或幅度变化：

$$c_l[m] \neq e^{j\phi[m]} c_l[0], \quad \text{for different } l,$$

那么多个 beams 之间的相干叠加关系会改变，等效波束方向、波束形状和接收增益都可能变化。

这种相对变化来自宽带多径信道。不同路径有不同 delay，不同子载波上路径相位会按 delay 旋转：

$$\mathbf{h}[m] \approx \sum_{p=0}^{P-1} \alpha_p e^{-j2\pi f_m \tau_p} \mathbf{a}(\theta_p, \phi_p).$$

如果所有路径 delay 相同，频率变化更接近公共相位；但真实多径中 τ_p 不同，因此各角度分量的相对相位会随频率变化。于是最优 precoder 在不同子带上不只是乘一个公共相位，而是需要调整不同 beam basis 的相对幅相。

对多层或多用户场景，这个问题更明显：即使某种旋转不改变单用户总接收功率，也可能改变 layer 间正交性、用户间干扰和每层 SINR。因此，子带微调或 R16 的 frequency-domain compression 真正关心的是：

哪些频率相关变化会改变有效 beam、有效层间结构和 SINR；而不是那些可以被接收机吸收的公共相位。

5.4 Tap selection, bitmap 与 strongest coefficient

为了控制反馈开销，R16 不会反馈完整 beam-tap 矩阵，而是只反馈其中最重要的一部分：

- 选择少量空间 beams；
- 选择少量 frequency taps；
- 用 bitmap 或相关指示表示非零位置；
- 对非零位置反馈量化幅度和相位；
- 标记 strongest coefficient 作为归一化和相位参考。

因此，R16 的本质不是“参数更多”，而是 **用更结构化的参数替代逐子带独立修正**。它把 R15 的空间稀疏表示扩展成空间-频率二维稀疏表示。

5.5 R15 与 R16 的根本差别

R15 和 R16 都有“宽带/子带”概念，但含义不同：

维度	R15 Type II	R16 Enhanced Type II
空间表示	多个 DFT beams	多个 DFT beams
频率处理	子带逐个修正	用 delay taps 统一建模
压缩结构	sparse vector per subband	sparse beam-tap matrix
核心思想	宽带给骨架，子带做 refinement	空间-频率联合压缩

一句话总结：**R15 是 hierarchical refinement，R16 才是真正意义上的 space-frequency compression。**

6. R17: Further Enhanced Type II Port-Selection 的端口选择增强

6.1 R17 的定位

R17 的主要增强对象是 **Further Enhanced Type II Port-Selection Codebook**。它不是推翻 R16 的空间-频率联合压缩框架，而是在 port-selection 分支上做工程化优化。

R17 仍然可以写成类似的 compact model:

$$\mathbf{W}_{\text{R17}} = \hat{\mathbf{W}}_s \mathbf{W}_c \hat{\mathbf{W}}_f^T.$$

但这里的 $\hat{\mathbf{W}}_s$ 不再是 regular codebook 中的 DFT beam basis，而是从 CSI-RS ports 对应的 standard basis 中抽取若干列。也就是说：

- R16 regular: 空间选择发生在 DFT beam domain;
- R17 port-selection: 空间选择发生在 beam-port domain。

6.2 从连续 port selection 到任意 port selection

port-selection 的直觉是：gNB 已经把 CSI-RS ports 做成了一组预波束，UE 只需要告诉 gNB 哪些 ports 更有用。

早期 port-selection 往往对可选 port 组合有限制，例如更偏向连续或规则的 port subset。R17 的关键增强是支持更灵活的任意 port selection：UE 可以从更大的 port 集合中选择 L 个重要 ports。这更符合 beam-domain channel 的真实稀疏结构，因为有效路径不一定落在连续 beam ports 上。

6.3 空间压缩比例与候选控制

任意 port selection 会带来组合数爆炸，因此 R17 需要控制候选集合规模。可以把它理解为：

1. gNB 暴露一组 CSI-RS beam ports;
2. UE 不在全部 ports 上做无约束组合;
3. 标准通过空间压缩比例、候选数等参数限制搜索和反馈开销;
4. UE 最终反馈被选 port subset 及其 beam-tap 系数。

这类机制的工程意义是：保留 port-selection 的灵活性，同时避免 PMI bit 数不可控。

6.4 频域 tap 反馈更轻量

R17 还简化或统一 tap 选择方式，降低 R16 中较复杂的 tap indication 负担，尤其面向 port-selection 场景做反馈开销优化。

因此，R17 的意义可以总结为：

R17 没有新增一个全新的压缩维度，而是把 R16 的空间-频率联合压缩更好地适配到 port-selection 分支：空间选择更灵活，频域反馈更轻量。

这使得 port-selection 更适合 hybrid beamforming、毫米波、大规模阵列和角域稀疏更强的场景。

7. R18: Predicted PMI 的时间域压缩与预测

7.1 R18 要解决的问题

R18 Enhanced Type II Codebook for Predicted PMI 在 R16/R17 的空间-频率压缩基础上进一步引入时间维度。它面向的问题是：在移动场景中，当前 slot 的 PMI 很快会过时，是否可以一次反馈一组结构化参数，用来预测未来若干时刻的 PMI。

从演进角度看：

R15: spatial compression → R16: spatial-frequency compression → R18: spatial-frequency-temporal compression.

7.2 时间域 basis 与 predicted PMI

R18 引入 temporal basis / shift / Doppler-domain 结构，用来描述 precoder 随时间的变化。矩阵形式可以理解为：

$$\mathbf{W}[n] = \hat{\mathbf{W}}_s \mathbf{W}_c[n] \hat{\mathbf{W}}_f^T, \quad n = 0, \dots, N_4 - 1.$$

其中 n 表示未来的 slot interval, N_4 表示预测时间维度上的采样数量。R18 新增的 shift / Doppler 相关 PMI 字段，可以理解为选择时间域 basis 的索引。

7.3 三维稀疏系数视角

如果把空间、频率和时间三个维度放在一起，R18 可以理解为在三维网格上选择少量重要系数。这个三维网格的三个轴分别是：

- 空间 beam 轴：由 $\mathbf{W}_s$ 给出；
- 频域 tap 轴：由 $\mathbf{W}_f$ 给出；
- 时间 shift 轴：由 $\mathbf{W}_t$ 给出。

为了避免使用某些 Markdown 渲染器不支持的张量乘法符号，可以不用写成复杂的 tensor product 公式，而直接理解为：

维度	basis	PMI 选择的对象
空间	$\mathbf{W}_s$	哪些 beams / ports 重要
频率	$\mathbf{W}_f$	哪些 delay taps 重要
时间	$\mathbf{W}_t$	哪些 Doppler shifts / temporal shifts 重要

因此，R18 的 PMI 可以看成是在 “beam, tap, shift” 三维位置上反馈少量非零系数。用文字写就是：

R18 PMI = selected beam/tap/shift positions + quantized coefficients.

换句话说，R18 的 predicted PMI 不是简单地 “多报几个未来 PMI”，而是用时间基底压缩未来 PMI 序列。

7.4 R18 与 R17 的关系

需要注意的是，R18 并不是 R17 port-selection 的直接延续。R17 的重点是 port-selection 分支的空间选择和频域反馈优化；R18 的重点是 predicted PMI，也就是时间维度上的结构化预测。二者都建立在 R16 的空间-频率联合压缩思想之上，但增强方向不同。

8. Compact Model、性能、反馈开销与适用场景

8.1 统一 compact model

R15 到 R18 的码本可以统一理解为：

$$\text{PMI feedback} = \text{support selection} + \text{quantized coefficient feedback}$$

support selection 表示选哪些 basis，coefficient feedback 表示这些 basis 上的量化幅度和相位。

从数学形式看，演进过程是：

Release	统一表示	稀疏对象
R15 Type II	$\mathbf{w} = \mathbf{W}_s \mathbf{w}_{\text{PMI}}$	sparse vector
R16/R17 Type II	$\mathbf{W} = \mathbf{W}_s \mathbf{W}_{\text{PMI}} \mathbf{W}_f^T$	sparse matrix
R18 Type II	在 beam / tap / shift 三维位置上反馈稀疏系数	sparse 3D coefficients

对应的物理稀疏性是：

数学基底	物理含义	压缩原因
spatial beam basis	角度 / AoD 结构	多径方向有限，角域稀疏
frequency tap basis	时延 / delay 结构	多径时延有限，delay-domain 稀疏
temporal shift basis	多普勒 / Doppler 结构	短时间内速度结构有限，Doppler-domain 稀疏

所以 5G NR 下行码本不是简单的“选波束表”，而是一套逐步扩展维度的结构化 CSI 压缩框架。

8.2 性能与反馈开销

从性能角度看，Type II 通常优于 Type I，尤其在大阵列、高 rank、多径角度分量丰富时更明显。原因很直接：Type I 主要做 coarse beam selection，而 Type II 能用多个 beams 和复系数重构更精细的 precoder。

从反馈开销看，R15 Type II 的表达能力强，但如果对子带逐个反馈幅相修正，开销会很高。R16 通过 frequency / delay-domain compression 显著降低宽带反馈量。R18 进一步通过 temporal compression 让 predicted PMI 不必逐时刻独立反馈。

可以这样理解：

- R15 Type I：低开销、低复杂度，但精度有限；
- R15 Type II：精度高，但宽带反馈开销较重；
- R16 Type II：利用频域相关性，降低宽带反馈开销；
- R17 Type II Port-Selection：优化 port-selection 的空间灵活性和 tap 反馈；
- R18 Type II Predicted PMI：利用时间相关性，面向移动场景减少未来 PMI 反馈负担。

8.3 适用场景

Codebook	适用场景	主要优势	主要限制
R15 Type I	低 rank、低复杂度、反馈受限场景	简单、鲁棒、开销低	precoder 表达能力有限
R15 Type II	大阵列、高精度 PMI、较高 rank 场景	多 beam 组合，性能好	反馈开销较高
R16 Enhanced Type II	宽带频率选择性明显的场景	空间-频率联合压缩	PMI 结构更复杂

Codebook	适用场景	主要优势	主要限制
R17 Port-Selection Type II	hybrid/mmWave/beam-domain 稀疏场景	port 选择灵活, 反馈更轻	依赖 gNB 侧 PEB 设计
R18 Predicted PMI Type II	移动场景、PMI 随时间可预测场景	时间域压缩, 支持未来 PMI	对预测稳定性和配置要求更高

8.4 最终主线

最终可以把 R15 到 R18 的演进压缩成一句话:

R15 解决空间域如何表示 precoder, R16 解决宽带频域如何压缩 precoder, R17 让 port-selection 分支更灵活高效, R18 则把 PMI 表达推进到时间域预测。

或者用统一公式概括:

beam support $\rightarrow$ beam/tap support $\rightarrow$ beam/tap/shift support.

这就是 R15 到 R18 下行码本演进最核心的逻辑。

9. R19: Large-Port CSI Feedback 与 Refined Codebooks

9.1 R19 的总体定位

如果说 R15 到 R18 的主线是不断增加压缩维度:

space $\rightarrow$ space-frequency $\rightarrow$ space-frequency-time,

那么 R19 的重点可以概括为:

把已有的 Type I / Enhanced Type II / Port-Selection / Predicted PMI 框架扩展到更大的 CSI-RS port 数。

R18 以前, 典型 codebook 讨论中 CSI-RS ports 通常最多到 32。R19 开始面向更大规模的 FR1 / sub-7 GHz MIMO 阵列, 引入 48、64、128 CSI-RS ports 下的 refined codebooks。

这意味着问题从:

$$P_{\text{CSI-RS}} \leq 32$$

扩展到:

$$P_{\text{CSI-RS}} \in \{48, 64, 128\}.$$

这不是简单把原有码本表“放大四倍”, 而是需要同时处理三个问题:

1. 大端口 CSI-RS 如何配置和测量;
2. UE 是否真的需要在完整 128-port 空间上做 PMI 推导;
3. Type I、Type II、port-selection、predicted PMI 如何复用已有结构。

因此, R19 的关键词不是新维度, 而是:

large-port support + refined codebook + resource aggregation

9.2 多个 CSI-RS resources 聚合成大端口集合

R19 中的 48、64、128 ports 往往不是由一个单独的 legacy CSI-RS resource 直接承载，而是通过多个 CSI-RS resources 聚合得到。

可以理解为：

$$P_{\text{tot}} = KP,$$

其中：

- P_{tot} ：聚合后的总 CSI-RS port 数，例如 48、64、128；
- K ：被聚合的 CSI-RS resource 个数；
- P ：每个 CSI-RS resource 中的 ports 数。

例如：

$$64 = 2 \times 32, \quad 128 = 4 \times 32.$$

直观上，UE 可以把多个 CSI-RS resources 看成一个更大的逻辑测量对象：

$$\underbrace{\text{Resource 0: ports } 0 \sim 31}_{32} + \underbrace{\text{Resource 1: ports } 32 \sim 63}_{32} + \dots$$

这样做的好处是：

- 复用已有 CSI-RS resource 映射规则；
- 避免重新定义一个过于复杂的单一 128-port CSI-RS resource；
- 允许 gNB 以更灵活的方式组织大规模逻辑端口；
- 为后续 refined codebook 提供统一的 port index 空间。

因此，R19 的大端口支持首先是一个 **CSI-RS resource aggregation** 问题，然后才是 PMI codebook 如何在该大端口集合上工作的问题。

9.3 为什么要裁剪端口集合：port subset 的作用

大端口支持带来一个直接问题：如果 UE 每次都在完整 128-port 空间中推导 PMI，计算复杂度、码本搜索空间和反馈结构都会变得很重。

因此 R19 引入端口子集裁剪机制。可以抽象为：

$$\{0, 1, \dots, P_{\text{tot}} - 1\} \rightarrow P_{\text{set}} \rightarrow \{0, 1, \dots, P_{\text{eff}} - 1\},$$

其中：

- P_{tot} 是聚合后的总端口数；
- P_{set} 是被启用的端口子集；
- P_{eff} 是 UE 实际用于 PMI 推导的有效端口数。

这个选择过程可以用一个选择矩阵表示：

$$\mathbf{h}_{\text{eff}} = \mathbf{S}_{P_{\text{set}}} \mathbf{h},$$

其中 $\mathbf{h}$ 是完整 large-port effective channel， $\mathbf{S}_{P_{\text{set}}}$ 只保留被启用的端口。

端口裁剪的意义主要有三点。

第一，降低 UE 的 PMI 推导复杂度。UE 不必总是在完整 48/64/128 维空间中搜索最优码本，而是在网络配置的有效端口子集上进行计算。

第二，复用已有 codebook 的连续端口假设。被启用的 ports 可以重新映射为连续 port indices，这样后续 Type I / Type II 公式仍然可以按一个连续的逻辑阵列来处理。

第三，适配用户的空间位置。对于某个 UE，并不是所有 ports 都有相同价值。若 UE 主要位于某个 panel、某个扇区或某个角域范围，gNB 可以让 CSI report 更集中在相关 port subset 上。

所以，port subset 并不是随便丢掉天线，而是在大端口系统中建立一个更合理的 PMI 推导空间：

$$\text{large port set} \rightarrow \text{effective port subset} \rightarrow \text{PMI derivation}$$

9.4 Refined Type I: 把低开销 beam selection 扩展到大端口

R19 新增 refined Type I single-panel / multi-panel codebook。它的物理直觉仍然接近 R15 Type I:

以较低反馈开销，在大端口逻辑阵列上选择一个或少数几个较合适的方向。

R15 Type I 可以理解为：

$$\mathbf{w} = \mathbf{W}_s \mathbf{e}_{l,m},$$

也就是从 DFT beam basis 中选一个主要 beam。

R19 refined Type I 可以理解为在更大端口维度上做同样的事情：

$$\mathbf{w}_{mR19-TypeI} = \mathbf{W}_s^{(P \leq 128)} \mathbf{e}_{l,m},$$

其中 $\mathbf{W}_s^{(P \leq 128)}$ 是大端口逻辑阵列上的空间基底。

但因为端口数变大，R19 refined Type I 需要额外考虑：

- ports 来自多个 CSI-RS resources 的聚合；
- 有效端口集合可能经过 port subset 裁剪；
- codebook subset restriction 需要适配更大的阵列形状；
- single-panel 和 multi-panel 场景需要不同配置。

因此，R19 refined Type I 的核心不是“更高精度”，而是：

在 48/64/128 ports 场景下，保留 Type I 的低复杂度和低反馈优势。

9.5 Refined eType II: 把 R16 的空间-频率压缩扩展到大端口

R16 Enhanced Type II 的核心模型是：

$$\mathbf{W} = \hat{\mathbf{W}}_s \mathbf{W}_c \hat{\mathbf{W}}_f^T.$$

其中 $\hat{\mathbf{W}}_s$ 是选中的空间 beams， $\hat{\mathbf{W}}_f$ 是选中的 delay taps， $\mathbf{W}_c$ 是 beam-tap 系数矩阵。

R19 refined eType II 的基本思想可以理解为：

$$\mathbf{W}_{mR19} = \hat{\mathbf{W}}_s^{(P \leq 128)} \mathbf{W}_c \hat{\mathbf{W}}_f^T.$$

也就是说：

- R16 解决的是空间-频率联合压缩;
- R19 不改变这个基本结构;
- R19 把空间维度扩展到 48/64/128 ports。

因此, R19 refined eType II 的本质是 large-port 版本的 Enhanced Type II。它继续利用两类稀疏性:

稀疏维度	对应 basis	物理来源
空间	beams / ports	有限角度路径
频率	delay taps	有限多径时延

相比 R16, R19 的难点在于空间维度更大。若不做裁剪和 refined restriction, beam support selection 和 coefficient bitmap 都会变得过重。因此 R19 需要结合 port subset、resource aggregation 和 refined codebook subset restriction 来控制复杂度。

9.6 Refined port-selection 与 refined predicted PMI

R19 并不只扩展 Type I 和 eType II。它还把 R17/R18 中已经出现的两个方向继续 refined:

1. **Refined FeTypeII Port Selection;**
2. **Refined eType II for predicted PMI.**

前者可以理解为 R17 port-selection 的 large-port 版本。R17 的核心是:

$$\mathbf{W} = \hat{\mathbf{W}}_s^{\text{port}} \mathbf{W}_c \hat{\mathbf{W}}_f^T,$$

其中 $\hat{\mathbf{W}}_s^{\text{port}}$ 是从 beam-domain CSI-RS ports 中选出的 standard basis。R19 refined port-selection 则是在更大的聚合 port 集合上继续做 port-domain 稀疏选择。

后者可以理解为 R18 predicted PMI 的 large-port 版本。R18 的核心是 beam/tap/shift 三维压缩:

$$\text{PMI} = \text{selected beam/tap/shift positions} + \text{quantized coefficients}.$$

R19 refined predicted PMI 则把空间维度改成 48/64/128-port 下的 refined spatial basis:

$$\text{space-frequency-time compression} \quad P_{\text{CSI-RS}} \leq 32 \rightarrow P_{\text{CSI-RS}} \in \{48, 64, 128\}.$$

所以, R19 的逻辑可以总结为:

R15-R18 既有方向	R19 refined 后的理解
Type I	large-port refined Type I
Enhanced Type II	large-port refined eType II
Further Enhanced Port Selection	large-port refined FeTypeII port selection
Predicted PMI	large-port refined eType II for predicted PMI

9.7 R19 的总结

R19 的核心不是增加新的压缩域，而是扩大已有结构的适用规模：

$$\text{R19} = \text{R16/R17/R18 codebook structure} + 48/64/128 \text{ ports} + \text{CSI-RS resource aggregation} + \text{port subset refinement}$$

它解决的是大规模逻辑阵列下的 CSI feedback 问题：

- 如何测量更多 CSI-RS ports;
- 如何避免 UE 在完整 128-port 空间中计算;
- 如何让 Type I、Type II、port-selection、predicted PMI 都能适配 large-port 场景;
- 如何保持 PMI payload 和 UE complexity 在可接受范围内。

因此，从 R15 到 R19 的演进可以扩展为：

single beam $\rightarrow$ multi-beam $\rightarrow$ beam+tap $\rightarrow$ port+tap $\rightarrow$ beam+tap+shift $\rightarrow$ large-port refined codebooks.

10. R20: 从“更大码本”走向“更低测量开销 + AI/ML CSI Feedback”

10.1 R20 的状态说明

R20 与 R15-R19 不完全一样。R15-R19 的许多 codebook 机制已经可以在 TS 38.214 中看到比较明确的规范文本；而 R20 仍处于 5G-Advanced 继续演进和早期 6G study 并行推进阶段。因此，对 R20 不能写成“某张最终码本表已经固定”。

更合理的表述是：

R20 的方向已经比较清楚，但具体规范细节仍应以最终冻结版本为准。

从 MIMO 下行 CSI 角度看，R20 至少有两条重要主线：

1. 降低 large-port CSI-RS acquisition 的测量开销;
2. 推进 AI/ML-based CSI feedback, 尤其是 two-sided CSI compression 模型。

10.2 Large-port CSI-RS density: 降低大端口测量资源开销

R19 支持 48/64/128 CSI-RS ports 后，一个新的瓶颈变得更加明显：

ports 越多 $\Rightarrow$ CSI-RS 测量资源越重。

如果仍然按照较高 density 发送 CSI-RS，则大端口 CSI acquisition 会占用大量下行 RE，并提高 UE 测量功耗。

CSI-RS density 可以粗略理解为 CSI-RS 在频域 RB 上出现的密度：

- $\rho = 1$: 每个 RB 都可能发送 CSI-RS;
- $\rho = 1/2$: 大约每两个 RB 中一个 RB 发送 CSI-RS;
- $\rho = 1/4$: 大约每四个 RB 中一个 RB 发送 CSI-RS;
- $\rho = 1/8$: 大约每八个 RB 中一个 RB 发送 CSI-RS。

测量资源开销可粗略表示为：

$$N_{\text{RE}}^{\text{CSI-RS}} \propto P_{\text{tot}} \cdot N_{\text{RB}} \cdot \rho \cdot N_{\text{occasion}}.$$

当 P_{tot} 从 32 增加到 128 时，若其他条件不变，端口维度已经增加 4 倍。因此 R20 讨论更低 CSI-RS density 的意义在于：

不只是让 UE 少反馈，而是首先让 UE 少测、网络少占用下行测量资源。

需要注意的是，CSI-RS density 本身并不直接等于 PMI feedback bit 数。它主要影响的是 **下行参考信号测量开销**。PMI payload 主要由 codebook type、有效 port 数、rank、subband 配置、beam/tap/shift 数量和非零系数个数决定。

可以把二者区分为：

项目	主要影响对象
CSI-RS density	下行测量 RE 开销、UE 测量复杂度
PMI payload	上行反馈比特、UCI/PUSCH/PUCCH 开销

当然，density 会间接影响反馈配置。例如测量更稀疏时，网络可能配置更粗粒度的 subband PMI 或更低报告频率，从而降低平均反馈开销。但这属于 report configuration 的变化，不是 density 字段本身直接减少 PMI bit。

10.3 AI/ML CSI feedback: 从固定码本到学习型压缩器

R15-R19 的传统码本都是 model-based codebook。它们的结构可以抽象为：

$$\text{PMI} = \text{basis selection} + \text{quantized coefficient feedback}.$$

其中 basis 通常是：

- DFT spatial beams;
- delay-domain DFT taps;
- Doppler-domain temporal shifts;
- 或 gNB 预形成的 beam-domain ports.

AI/ML CSI feedback 的思路则更像一个端到端压缩器：

$$\mathbf{z} = f_{\text{UE}}(\mathbf{H}_{\text{eff}}),$$

$$\hat{\mathbf{W}} \text{ or } \hat{\mathbf{H}} = g_{\text{gNB}}(\mathbf{z}).$$

其中：

- $f_{\text{UE}}(\cdot)$ 是 UE 侧 encoder;
- $g_{\text{gNB}}(\cdot)$ 是 gNB 侧 decoder;
- $\mathbf{z}$ 是压缩后的反馈 payload;
- $\hat{\mathbf{W}}$ 或 $\hat{\mathbf{H}}$ 是 gNB 重构出的 precoder 或 CSI 表示。

这类 two-sided 模型和传统 codebook 的最大差别是：

传统码本的基础 basis 是协议预定义的；AI/ML feedback 的压缩表示可能由数据学习得到。

因此，AI/ML CSI feedback 不再只是“选哪个 beam、哪个 tap、哪个 shift”，而是可能学习更复杂的信道统计结构、阵列结构和场景相关特征。

10.4 AI/ML 不会立刻替代传统码本

虽然 AI/ML CSI feedback 很有吸引力，但短期内更合理的理解不是“替代 Type II”，而是与传统码本并存。

传统 Type II / eType II 的优点是：

- 物理含义清楚；
- 标准化和互操作性强；
- UE/gNB 行为容易测试；
- fallback 机制明确；
- 可解释性好。

AI/ML feedback 的潜在优势是：

- 可以学习非理想阵列、硬件和场景相关结构；
- 可适配 near-field、distributed MIMO、非规则阵列等更复杂场景；
- 有可能在相同反馈比特下获得更好的 CSI 重构质量；
- 可与 prediction、mobility、site-specific channel statistics 结合。

但它也带来新的标准化难题：

1. UE 和 gNB 的模型如何匹配；
2. 不同厂商的 encoder/decoder 如何互操作；
3. 模型 ID、版本、激活、去激活、切换如何管理；
4. 模型失配或性能退化时如何 fallback；
5. UE 计算复杂度、功耗和时延如何约束；
6. 一致性测试如何定义。

所以，R20 的 AI/ML CSI feedback 更像是在建立框架：

traditional codebook fallback + AI/ML CSI compression enhancement

10.5 R20 的总结

R20 的 MIMO 下行 CSI 方向可以概括为：

R20 = large-port CSI acquisition optimization + AI/ML CSI feedback framework

它相比 R19 的变化不是继续简单增加 port 数，而是进一步追问：

- 128 ports 已经可以反馈了，但 CSI-RS 测量成本太高怎么办；
- 传统 DFT/tap/shift basis 够不够描述未来更复杂的 MIMO 场景；
- 能不能用数据驱动方法学习更有效的 CSI 压缩方式；
- 如何在保持标准互操作性的同时引入 AI/ML 模型。

从这个意义上说，R20 是从 5G-A 传统 codebook 走向 6G AI-native CSI feedback 的过渡阶段。

11. 从 R15 到 R20 的完整演进主线

11.1 用一句话概括

R15 到 R20 的 MIMO 下行码本演进，可以概括为：

从单 beam 选择，走向空间-频率-时间多维稀疏压缩；再走向大端口 refined codebook 和 AI/ML 辅助 CSI feedback。

更形式化地写:

$$\text{R15 Type I : } \mathbf{w} = \mathbf{W}_s \mathbf{e}$$

$$\text{R15 Type II : } \mathbf{w} = \mathbf{W}_s \mathbf{w}_{\text{PMI}}$$

$$\text{R16/R17 : } \mathbf{W} = \mathbf{W}_s \mathbf{W}_{\text{PMI}} \mathbf{W}_f^T$$

R18 : sparse coefficients over beam/tap/shift

$$\text{R19 : } P_{\text{CSI-RS}} \leq 32 \rightarrow P_{\text{CSI-RS}} \in \{48, 64, 128\}$$

R20 : lower CSI-RS acquisition overhead + AI/ML CSI compression.

11.2 演进表

Release	核心升级	主要解决的问题	关键直觉
R15 Type I	单 beam / beam group selection	低复杂度 PMI 反馈	选一个较好的方向
R15 Type II	multi-beam combination	单 beam 精度不足	用多个 beams 重构 precoder
R16 Enhanced Type II	frequency-domain compression	宽带子带反馈太重	用 delay taps 压缩 across-subband PMI
R17 Further Enhanced Port Selection	flexible port selection	beam-domain ports 不一定连续	在 gNB 预波束端口中灵活选子集
R18 Predicted PMI	temporal compression	移动场景 PMI 易过时	用 Doppler shifts 描述未来 PMI 变化
R19 Refined Codebooks	48/64/128 ports	大规模逻辑端口反馈	resource aggregation + port subset + refined codebook
R20 CSI/AI Enhancements	lower density + AI/ML feedback	大端口测量开销和传统 basis 限制	少测量 + 学习型压缩

11.3 最终理解框架

可以把整个下行码本演进理解为三个阶段。

阶段一：空间域码本 对应 R15:

beam selection / beam combination.

目标是用有限 PMI 描述空间方向。

阶段二：多维结构化压缩 对应 R16-R18:

beam $\rightarrow$ beam+tap $\rightarrow$ beam+tap+shift.

目标是利用空间、频率、时间上的稀疏性降低反馈开销。

阶段三：大端口与 AI-native 过渡 对应 R19-R20:

large-port refined feedback $\rightarrow$ AI/ML CSI compression.

目标是面向更大阵列、更复杂部署和更强移动性，建立可扩展的 CSI acquisition 与 feedback 框架。

12. 总结

5G NR MIMO 下行码本不是一组孤立的表格，而是一套逐步演进的 CSI 压缩思想。

从 R15 到 R18，压缩维度不断增加：

space $\rightarrow$ space-frequency $\rightarrow$ space-frequency-time.

从 R19 到 R20，问题重心进一步变化：

higher-dimensional feedback $\rightarrow$ large-port scalable feedback $\rightarrow$ AI/ML-assisted feedback.

因此，理解 MIMO 下行码本时，最重要的不是记住每个 PMI 字段，而是抓住这条主线：

有限反馈下，如何利用信道结构重构足够好的下行 precoder

R15 用 beam 结构，R16 用 delay 结构，R18 用 Doppler 结构，R19 扩展到 large ports，R20 则开始引入更低测量开销和学习型压缩。这条主线也会自然延伸到 6G 中的 XL-MIMO、near-field MIMO、distributed MIMO 和 AI-native air interface。